



大数据分析

BIG DATA ANALYTICS

大数据分析

Big Data Analysis



大数据分析概述

数据科学与知识工程研究所
北京理工大学计算机学院



结构大纲

1

大数据基本概念

2

数据获取

3

数据预处理

4

数据存储系统

5

数据处理系统

6

大数据计算平台和应用

7

实验



结构大纲

1

大数据基本概念

2

数据获取

3

数据预处理

4

数据存储系统

5

数据处理系统

6

大数据计算平台和应用

实验



第一章 大数据基本概念

1.1 大数据基本概念

1.2 结构化数据和非结构化数据

1.3 科学研究第四范式

1.4 大数据特征

1.5 大数据生命周期

1.6 大数据处理流程

1.7 大数据通用架构



第一章 大数据基本概念

1.1 大数据基本概念

1.2 结构化数据和非结构化数据

1.3 科学研究第四范式

1.4 大数据特征

1.5 大数据生命周期

1.6 大数据处理流程

1.7 大数据通用架构



第二章 数据获取

2.1 大数据数据来源

2.2 内部数据源数据获取

2.3 外部数据源数据获取

2.4 深网数据获取



第三章 数据预处理

3.1 数据预处理概述

3.2 数据质量

3.3 数据清洗技术

3.4 数据转换

3.5 数据归约



第三章 数据预处理

3.1 数据预处理概述

3.2 数据质量

3.3 数据清洗技术

3.4 数据转换

3.5 数据归约

大数据通用架构

数据应用系统

数据应用系统

- 大数据应用
- 大数据产品和服务
- 数据可视化

数据处理系统

数据处理系统

- 计算引擎和平台
- 计算模型
- 计算算法

数据存储系统

数据存储系统


- 统一数据访问接口
- 分布式数据库或数据仓库
- 分布式文件系统
- 数据收集与建模



第四章 数据存储系统

数据存储系统

- 统一数据访问接口
- 分布式数据库或数据仓库
- 分布式文件系统
- 数据收集与建模



统一数据访问接口

针对不同数据类型、多样化和多种标准技术的大数据应用的跨平台异构数据库的统一访问问题

- 数据**逻辑**存储 - DB & DW
 - NoSQL DB V.S. DBMS (优势和劣势, 各自适合的场景)
 - 特征: CAP 和BASE理论
-
- 数据**物理**存储 -DFS (HDFS, GFS)
 - 什么是HDFS, 如何工作, 包括数据读写过程和容错机制。

- 数据源
 - 数据预处理
 - 数据清洗
 - 抽取
 - 标准存储格式
 - 建模
- 相互独立 而且要保持一致

数据模型

概念模型

逻辑模型

物理模型



第五章 数据处理系统

数据处理系统

- 计算引擎和平台
- 计算模型
- 计算算法



针对于不同类型的数据的计算模型:

- ① 针对大量数据的批处理模型MapReduce
- ② 针对动态数据流的流计算模型
- ③ 结构化数据的大规模并发处理 (MPP) 模型
- ④ 使用大规模物理内存的内存计算模型
- ⑤ 并行图计算模型



算法

机器学习 / 数据挖掘

有监督、无监督、半监督和增强学习/分类. 聚类 回归. 关联分析



第六章 数据应用系统

数据应用系统

- 大数据应用
- 大数据产品和服务
- 数据可视化



推荐系统

社交网络分析





第六章 数据应用系统

数据应用系统

- 大数据应用
- 大数据产品和服务
- 数据可视化

推荐系统


社交网络分析





实验

动手实验



网络爬虫

推荐系统

社交网络分析




推荐系统

社交网络分析



实验

动手 实验



网络爬虫

静态网络爬虫

动态网络爬虫



推荐系统

社交网络分析

Big Data Analysis



谢谢!

数据科学与知识工程研究所
北京理工大学计算机学院