



大数据分析

BIG DATA ANALYTICS

第一章



1.2 大数据基本概念 结构化数据和非结构化数据

数据科学与知识工程研究所
北京理工大学计算机学院



结构化数据和非结构化数据

ID	Forename	Surname	Age
0	Arnold	Schwarzenegger	71
1	Sylvester	Stallone	72
2	Chuck	Norris	79




Structured Data


VS

Unstructured Data

以行和列的
表格形式，存储
在关系型数据库



数字、日期
和字符串



据 Gartner 估计，
组织的 20% 数据
是结构化数据




更少的存储空间



使用遗留解决方案
更易于管理和保护



不能在行、列和
关系数据库中显示



图像、音频、视频、
文字处理文件、
电子邮件、电子表格



据 Gartner 统计
企业数据的 80% 是
非结构化数据



需要更多存储空间




很难以传统方式
使用遗留解决方案
进行管理和保护






结构化数据和非结构化数据






非结构化数据中隐藏着什么？



NPS (Net Promoter Score) 口碑
CSAT-Client Satisfaction 客户满意度

非结构化数据中隐藏着什么？



Source: Graphic adapted from January 2018 CXPA Presentation "The Why Behind the What," Jim Kitterman



大数据比喻

	DB (Database)	BD (Big Data)
	在水池里钓鱼	在海里钓鱼
规模	MB	GB TB PB
种类	一些种类的鱼； 结构化的	成千上万种鱼； 结构化，非结构化，半结构化
结构 Schema	First schema, then data 先有结构后又数据	First data then schema for data 先有数据，然后为数据设计结构
数据	数据只是用来被处理的 对象	通过一些数据感知其他数据
工具	一个工具解决所有问题	没有工具可以解决所有问题

$$1\text{KB}=2^{10}\text{B}=1024\text{B};$$

$$1\text{MB}=2^{10}\text{KB}=1024\text{KB}=2^{20}\text{B}$$

$$1\text{GB}=2^{10}\text{MB}=1024\text{MB}=2^{30}\text{B}$$

$$1\text{TB}=2^{10}\text{GB}=1024\text{GB}=2^{40}\text{B}$$

$$1\text{PB}=2^{10}\text{TB}=1024\text{TB}=2^{50}\text{B}$$

$$1\text{EB}=2^{10}\text{PB}=1024\text{PB}=2^{60}\text{B}$$

大数据分析

Big Data Analysis



谢谢!

数据科学与知识工程研究所
北京理工大学计算机学院