



大数据分析

BIG DATA ANALYTICS

第一章




1.3科学研究第四范式

数据科学与知识工程研究所
北京理工大学计算机学院



科学研究第4范式




Jim Gray，关系型数据库的创始人；航海运动爱好者。

2007年国家研究委员会，计算机科学与电信委员会科学方法的革命。

2007年1月28日，永远消失在海上。

2007年1月17日在加利福尼亚州山景城举行的 NRC-CSTB，美国国家研究委员会-计算机科学和电信委员会会议上，他发表了她的最后一场演讲，“科学方法的革命”，将科学研究分为四种范式。



Science Paradigms	Time	Methodology
Empirical	Thousand years ago	Describing natural phenomena
Theoretical	Last few hundred years	Using models, generalizations
Computational	Last few decades	Simulating complex phenomena
Data Exploration (eScience)	Today	Data captured by instruments or generated by simulator; Processed by software; Information stored in computer; Scientist analyzes database




The fourth Paradigm

Science Paradigms

- Thousand years ago:
science was **empirical**
describing natural phenomena
- Last few hundred years:
theoretical branch
using models, generalizations
- Last few decades:
a **computational** branch
simulating complex phenomena
- Today: **data exploration** (eScience)
unify theory, experiment, and simulation
 - Data captured by instruments or generated by simulator
 - Processed by software
 - Information/knowledge stored in computer
 - Scientist analyzes database/files using data management and statistics

$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{4\pi G\rho}{3} - K\frac{c^2}{a^2}$$



1

上千年前，科学是经验主义的，人们通过描述自然现象来做科学。和中国古代一样，耕作是通过观察天象来完成的。




The fourth Paradigm

Science Paradigms

- Thousand years ago:
science was **empirical**
describing natural phenomena
- Last few hundred years:
theoretical branch
using models, generalizations
- Last few decades:
a **computational** branch
simulating complex phenomena
- Today: **data exploration** (eScience)
unify theory, experiment, and simulation
 - Data captured by instruments
or generated by simulator
 - Processed by software
 - Information/knowledge stored in computer
 - Scientist analyzes database/files
using data management and statistics

$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{4\pi G\rho}{3} - K\frac{c^2}{a^2}$$



2 过去几百年，理论分支，使用模型，概括。

- 从原始的钻木取火，发展到以伽利略为代表的文艺复兴时期的科学发展初期。很难对自然现象进行更准确的认识。科学家们开始尝试尽可能地简化实验模型，去除一些复杂的干扰，只留下关键因素（例如，“足够流畅”、“足够长的时间”、“足够稀薄的空气”等。物理学习，就是莫名其妙的条件描述），然后通过微积分来总结，这是科学研究的第二范式。这种研究范式一直持续到19世纪末，堪称完美。
- 牛顿三定律成功解释了经典力学，麦克斯韦理论成功解释了电磁学，经典物理大厦宏伟壮观。但在量子力学和相对论出现之后，以理论研究为主，以非凡的大脑思维和复杂的计算超越了实验设计。
- 随着理论验证的难度和越来越高的经济投入，科学研究开始显得力不从心。




The fourth Paradigm

Science Paradigms

- Thousand years ago:
science was **empirical**
describing natural phenomena
- Last few hundred years:
theoretical branch
using models, generalizations
- Last few decades:
a **computational** branch
simulating complex phenomena
- Today: **data exploration** (eScience)
unify theory, experiment, and simulation
 - Data captured by instruments
or generated by simulator
 - Processed by software
 - Information/knowledge stored in computer
 - Scientist analyzes database/files
using data management and statistics

$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{4\pi G\rho}{3} - K\frac{c^2}{a^2}$$



3

20世纪中叶，冯·诺依曼提出了现代电子计算机体系结构，用电子计算机模拟科学实验的模式迅速普及。人们通过模拟可以推断出越来越多的复杂现象。

典型案例包括模拟核试验和天气预报。随着计算机模拟日益取代实验，逐渐成为科学研究的常规方法，是科学研究的第三范式。




The fourth Paradigm

Science Paradigms

- Thousand years ago:
science was **empirical**
describing natural phenomena
- Last few hundred years:
theoretical branch
using models, generalizations
- Last few decades:
a **computational** branch
simulating complex phenomena
- Today: **data exploration** (eScience)
unify theory, experiment, and simulation
 - Data captured by instruments
or generated by simulator
 - Processed by software
 - Information/knowledge stored in computer
 - Scientist analyzes database/files
using data management and statistics



$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{4\pi G\rho}{3} - K\frac{c^2}{a^2}$$



4

科学未来的发展趋势是随着数据的爆炸式增长，计算机不仅可以进行模拟，还可以进行分析总结，产生理论。

- 数据密集型范式应该从第三范式中分离出来，成为一种独特的科学研究范式。这种科学研究方法被称为第四范式。科学研究的第四范式和科学研究的第三范式。两者都使用计算机进行计算。这两种科学研究范式有什么区别？
- “什么是科学问题？”，“什么是科学假设？”首先提出可能的理论，然后收集数据，然后通过计算验证它们。
- 基于大数据的第四范式是先拥有大量已知数据，然后再计算以前未知的理论。



全量数据取代样本数据-监测雾霾



根据现有机理理解，雾霾天气的形成不仅与来源，大气的化学成分，还与地形、风向、温度、湿度和气象因素。

--一些“代表”地点建立气象站



手机监测温湿度，定位空间位置，监测大气环境化学和PM2.5功能传感设备。移动监测终端增加了测量的空间覆盖范围，产生了海量的数据。利用这些数据，分析雾霾的成因，做出预测。

样本数据

VS

全量数据



相关性取代因果关系

2004 沃尔玛购物清单中，系统记录了消费金额、购物篮中的物品、具体的购买时间，甚至是购买的天气。

- 每当季节性飓风来临时，不仅手电筒的销量会增加，蛋挞的销量也会增加。蛋挞在飓风相关用品边上摆放，结果增加了销量。



颠覆了人类几千年来思维常规，对人类的认知和与世界的交流方式提出挑战。

人类总是思考事物之间的因果关系，对基于数据的相关性不是那么敏感；相反，计算机本身很难理解因果关系，擅长相关性分析。

维克多·迈耶-勋伯格《大数据时代》中：大数据时代最大的变化是摒弃了对因果关系的渴望，即因果关系，转而关注相关性。

Big Data Analysis



谢谢!

数据科学与知识工程研究所
北京理工大学计算机学院