



大数据分析

BIG DATA ANALYTICS

第一章



1.4 大数据特征

数据科学与知识工程研究所
北京理工大学计算机学院




3Vs, 4Vs, 5Vs



规模
速度
种类



大数据 = 交易 + 交互 + 观测







规模

数据规模

- 从 2009 年到 2020 年增长了 44 倍
- 从 0.8 zettabytes 到 35 zettabytes
- 数据量呈指数级增长



IDC 《数据时代2025》报告，到2025年，全球数据将达到175 ZB（2009年的218.75倍）。

$$1 \text{ ZB} = 2^{70} \text{ B}$$



Earthscope项目

- Earthscope地球范围是世界上最大的科学项目。

该天文台旨在追踪北美的地质演化，记录超过 380 万平方英里的数据，积累 67 TB 的数据。

它分析了圣安地列斯断层的地震滑动，当然还有黄石公园下方的岩浆羽流等等。



大数据分析



种类 (复杂性)







种类 (复杂性)

- 关系数据 (表/事务/遗留数据)
- 文本数据 (网络)
- 半结构化数据 (XML)
- 图表数据

社交网络、语义网 (RDF)、

- 流数据
- 您只能扫描一次数据
- 单个应用程序可以生成/收集多种类型的数据
- 公共大数据 (在线、天气、金融等)



为了提取知识→所有这些类型的数据都需要链接在一起

客户的单一视图





Velocity 速度

- 数据生成速度快，需要快速处理。
- 在线数据分析
- 迟的决策→错过机会



例子

电子促销：根据您当前的位置、您的购买历史、推断你的喜好 → 立即给您发送附近的商店促销信息

健康检测：监测您的活动和身体的传感器 → 任何异常指标都需要立即反应





实时/快速数据



社交媒体和网络

(我们所有人都在生成数据)




科学仪器

(收集各种数据)



移动设备

(一直跟踪所有对象)



传感器技术和网络

(测量各种数据)

- 收集数据的能力不再阻碍进步和创新
- 但是，通过及时和可扩展的方式管理、分析、总结、可视化和从收集的数据中发现知识的能力。



实时分析/决策要求

— 当它发生时采取行动

相关且有说服力
的产品推荐

在收银台付款时了
解为什么客户转向
竞争对手及其报价

影响
行为

当促销还没过期的
时候改善一个促销
活动的营销有效性

Customer

邀请好友加入
能够拓展业务
的游戏或活动


在欺诈交易发生时防止
并更主动地预防



5V' s

“

规模




静止
的数据

TB到GB的
现存数据
要处理

“

速度




运动中的
数据

流数据
几毫秒到几秒
的反应时间

“

种类




多种形式的
数据

结构化
非结构化
文本，
多媒体数据

“

真伪



可疑
的数据

由于数据不一致
和不完整、歧义、
延迟、欺骗、模
型近似而导致的
不确定性

“

价值



价值密度
也很低

像在沙子中淘金
几个小时的视频
中的几秒钟可能
是有用的。

Big Data Analysis



谢谢!

数据科学与知识工程研究所
北京理工大学计算机学院