



大数据分析

BIG DATA ANALYTICS

第一章



1.7 大数据通用架构

数据科学与知识工程研究所
北京理工大学计算机学院



从集中式到分布式


Centralized集中式

VS

Distributed分布式



- 高性能
- 高可靠性
- 高价格



- 分布式存储
- 高冗余
- 分布式处理
- 低价格



从集中式到分布式


Centralized集中式

VS

Distributed分布式



- 高性能
- 高可靠性
- 高价格



- 分布式存储
- 高冗余
- 分布式处理
- 低价格



大数据的两个主要组成部分



Distributed Storage
分布式存储

Distributed Processing
分布式处理



大数据的两个主要组成部分



Distributed Storage
分布式存储

Distributed Processing
分布式处理



大数据通用架构

大数据计算系统的三个基本层次：

① 数据存储系统

② 数据处理系统

③ 数据应用系统

3.数据应用系统

- 3.1 大数据应用
- 3.2 数据产品和服务
- 3.3 数据可视化

2.数据处理系统

- 2.1 算法
- 2.2 计算模型
- 2.3 计算引擎和计算平台

1.数据存储系统

- 1.1 分布式数据库/数据仓库
- 1.2 分布式文件系统
- 1.3 数据获取和建模



数据存储系统

1. 数据存储系统

- 1.1 分布式数据库/数据仓库
- 1.2 分布式文件系统
- 1.3 数据获取和建模

- 1. 数据收集层
- 2. 数据清洗，提取和建模；
- 3. 数据存储架构（物理存储和逻辑存储）
- 4. 统一数据访问接口等

L4 Unified Data Access Interface统一数据访问接口



L3 NoSQL 数据库 (HBase / BigTable / MongoDB / Neo4j)



L2 分布式文件系统 (HDFS / GFS / Colossus)



L1 数据采集/ 提取 / 转换 / 建模





S1-L4 : ODBC-DAL-UDAI (Unified Data Access Interface)

1.ODBC; JDBC

所有数据库操作均由相应的 ODBC 驱动程序完成。

为了实现分布式
计算

Evolved to

2.DAL-Data Access Layer数据访问层

- ① CRUD（数据库创建检索更新和删除）。
- ② 交易管理，
- ③ 并发调度，
- ④ 缓冲区管理，
- ⑤ 异构数据库转换
- ⑥ 分布式计算环境中的继承

DAO，基于ORM（Object/relation Mapping）的实现，服务数据对象，服务中间件。

为了实现
跨平台异
构数据库

Evolved to

3.Unified Data Access Interface

针对不同数据类型，大数据应用的多种类型多种数据标准需要跨平台异构数据库；

平台：UNIX, Linux or Windows；

数据类型：表单，邮件，XML 文档，EJB 组件，Web 服务，图片，音频/视频 文件 或其他非结构化数据；

数据访问层的设计需要兼容不同标准的技术和产品。

为了实现
跨平台异构
数据库




数据处理系统

2.数据处理系统

2.1 算法

2.2 计算模型

2.3 计算引擎和计算平台





数据应用系统

3.数据应用系统

3.1 大数据应用

3.2 数据产品和服务

3.3 数据可视化

基于上述计算架构和处理平台，提供了各行业、各领域的大数据应用技术解决方案。目前，互联网、电子商务、电子政务、金融、电信、医疗卫生等行业是大数据应用最热门的领域，而制造、教育、能源、环保、智能交通是大数据技术将会或已经开始拓展产业的领域。




数据应用系统


“ 3.数据应用系统

- 3.1 大数据应用
- 3.2 数据产品和服务
- 3.3 数据可视化

基于上述计算架构和处理平台，提供了各行业、各领域的大数据应用技术解决方案。目前，互联网、电子商务、电子政务、金融、电信、医疗卫生等行业是大数据应用最热门的领域，而制造、教育、能源、环保、智能交通是大数据技术将会或已经开始拓展产业的领域。



大数据分析





BIG DATA is not just HADOOP

O'REILLY®

O'Reilly Media 的 Roger Mougals 于 2005 年首次使用了大数据一词。指大公司每天收集的大量数据。雅虎！ 2005 年开发了 Hadoop 来索引万维网。作为一个开源系统，Hadoop 用于分析全世界的海量数据。

了解和导航联合大数据源



联合发现和导航

管理和存储大量数据



Hadoop 文件系统HDFS
MapReduce

结构和控制数据



数据仓库

管理流数据



流计算

分析非结构化数据



文本分析引擎

集成和管理所有数据源



集成、数据质量、安全性、
生命周期管理、MDM

Big Data Analysis



谢谢!

数据科学与知识工程研究所
北京理工大学计算机学院